

面向复杂学术查询的智能论文搜索与推荐 Agent 工作流 V2.0

一、总体调整思路

原工作流更偏向“固定检索 Pipeline”，优点是稳定、成本可控，但与赛题中“基于大模型的自主搜索策略迭代优化”要求还不完全匹配。赛题要求系统不仅要理解查询，还要能够自主规划搜索词、过滤不相关和低质量论文，并根据已找到的相关论文动态调整检索策略。

因此，本项目最终工作流调整为：

LLM 主控 Agent + 多工具检索 + 反思式迭代优化 + 证据约束排序 + 结构化归纳展示

其中，LLM 不只是用来改写 query，而是作为 Agent 的“策略控制器”，参与以下关键环节：

1. 理解用户复杂查询；
2. 生成第一轮检索计划；
3. 审阅第一轮检索结果；
4. 发现缺失方向、噪声来源和关键词不足；
5. 生成第二轮或第三轮检索策略；
6. 判断是否需要引用扩展；
7. 对候选论文做相关性解释；
8. 输出结构化搜索总结。

但为了避免 Agent 无限制搜索，本方案仍然保留 BudgetManager、最大迭代轮数、Token 预算和停止条件。

二、最终 Agent 工作流总览

输入：用户复杂学术查询



阶段 1: LLM Query Understanding Agent

- 解析研究意图
- 抽取主题、方法、数据集、时间、venue、领域、排除项
- 形成 Query Contract



阶段 2: LLM Search Planning Agent

- 生成第一轮搜索策略
- 生成中英文检索式
- 生成 3-5 个子查询
- 选择搜索源和检索方式



阶段 3: Tool-based Multi-source Retrieval

- OpenAlex
- Semantic Scholar
- arXiv
- PubMed

- 本地论文库 / PaSa 数据
- BM25 / BGE-M3 / SPECTER2

↓

阶段 4: LLM Result Review Agent

- 审阅当前候选论文
- 判断候选结果是否覆盖用户需求
- 识别漏掉的研究方向
- 识别噪声论文类型
- 发现新的关键词、方法名、数据集名、代表论文

↓

阶段 5: LLM Search Strategy Optimization Agent

- 生成下一轮搜索策略
- 追加新关键词
- 改写检索式
- 决定是否进行引用扩展
- 决定是否扩大或收缩搜索范围

↓

阶段 6: Iterative Search Loop

- 最多迭代 2-3 轮
- 每轮检索后由 LLM 审阅并优化
- 满足停止条件后进入最终筛选

↓

阶段 7: Evidence-based Filtering Agent

- 过滤不相关论文
- 过滤低质量论文
- 区分高度相关、部分相关、低相关
- 给出 evidence span

↓

阶段 8: Comprehensive Reranking

- 结合 LLM 判断、BGE-reranker、约束命中、语义分数、引用关系、时间、权威性
- 输出最终排序

↓

阶段 9: LLM Synthesis Agent

- 按用户意图归纳搜索结果
- 输出高度相关论文
- 输出部分相关论文
- 输出方法分类
- 输出时间线
- 输出引用关系图
- 输出推荐理由

三、Agent 角色重新划分

最终系统不建议做多个完全自由的 Agent，而应设计为“角色清晰、状态共享、预算受控”的多 Agent 协作。

3.1 Query Understanding Agent: 查询理解 Agent

任务

负责把用户自然语言查询转成结构化 Query Contract。

输入

用户原始复杂查询

输出

```
{
  "research_intent": "用户核心研究意图",
  "topic": "主题",
  "methods": ["方法1", "方法2"],
  "datasets": ["数据集1"],
  "domains": ["领域"],
  "time_range": [2022, 2026],
  "venues": ["ACL", "EMNLP", "NeurIPS"],
  "must_have_constraints": [],
  "nice_to_have_constraints": [],
  "negative_constraints": [],
  "query_type": "survey / latest / method_comparison / dataset_constraint / citation_tracking"
}
```

作用

这一阶段解决赛题要求中的：

解析用户自然语言查询中的核心研究意图，识别关键实体、方法论约束、数据/领域限定等多维检索条件。

3.2 Search Planning Agent: 搜索规划 Agent

任务

根据 Query Contract 生成第一轮搜索计划。

输出内容

1. 搜索源选择；
2. 搜索关键词；
3. 中英文检索式；
4. 子查询；
5. 每条子查询的目的；
6. 每条子查询使用的检索方式。

示例输出

```
{
  "round": 1,
  "search_goal": "建立候选论文池，覆盖主题、方法和数据集约束",
  "subqueries": [
    {
      "query": "LLM agents for academic paper search and recommendation",
      "purpose": "搜索核心主题论文",
      "sources": ["Semantic Scholar", "OpenAlex"],
      "retrievers": ["BM25", "BGE-M3"]
    },
    {
      "query": "citation-aware scholarly paper recommendation reranking",
      "purpose": "搜索引文网络和重排序相关论文",
      "sources": ["Semantic Scholar"],
      "retrievers": ["BM25", "SPECTER2"]
    },
    {
      "query": "academic search agent query decomposition scholarly retrieval",
      "purpose": "搜索查询分解与搜索 Agent 相关论文",
      "sources": ["arXiv", "OpenAlex"],
      "retrievers": ["BGE-M3"]
    }
  ],
  "expected_evidence": [
    "title contains paper search / scholarly retrieval",
    "abstract mentions LLM agent / query decomposition / reranking",
    "paper has citation or benchmark evaluation"
  ]
}
```

作用

这一阶段解决赛题要求中的：

对复杂查询进行子查询分解，将宽泛或组合式的学术问题拆解为可独立检索的子问题。
支持查询改写与扩展，生成更适合检索引擎的查询。

3.3 Retrieval Tool Layer：检索工具层

这一层不是 Agent，而是 Agent 可以调用的工具。

工具类型

工具	作用
OpenAlex Search Tool	获取论文元数据、年份、作者、引用关系

工具	作用
Semantic Scholar Tool	获取论文、引用、被引、相似论文
arXiv Tool	获取最新预印本
PubMed Tool	获取生物医学论文
BM25 Tool	关键词精准检索
BGE-M3 Tool	强语义检索
SPECTER2 Tool	科学论文语义检索
Citation Expansion Tool	查参考文献、被引论文、相似论文
Dedup Tool	去重合并
Cache Tool	缓存历史结果

说明

LLM Agent 不直接“凭空生成论文”，而是通过工具获取候选论文。每篇候选论文都必须有来源记录。

3.4 Result Review Agent：检索结果审阅 Agent

这是新增的关键模块，也是对赛题第二条要求最重要的响应。

任务

每一轮检索后，LLM 审阅当前候选结果，判断检索是否充分，并提出下一轮搜索优化建议。

输入

Query Contract
 当前检索计划
 当前候选论文 top 50
 候选论文的标题、摘要、年份、venue、来源、初步分数
 候选池统计信息

输出

```
{
  "coverage_analysis": {
    "covered_aspects": [
      "LLM agent for paper search",
      "query decomposition",
      "academic retrieval"
    ],
    "missing_aspects": [
      "citation-aware reranking",
```

```

    "benchmark evaluation",
    "recent 2025 works"
  ],
  "noise_patterns": [
    "general RAG papers unrelated to scholarly search",
    "recommendation papers without paper retrieval"
  ]
},
"candidate_quality": {
  "enough_candidates": false,
  "hard_constraint_coverage": "medium",
  "precision_risk": "high",
  "recall_risk": "medium"
},
"next_action": "continue_search",
"suggested_new_keywords": [
  "citation-aware scholarly retrieval",
  "academic search benchmark",
  "paper recommendation reranking",
  "scholarly agent evaluation"
],
"suggested_excluded_terms": [
  "general chatbot",
  "web search only",
  "non-academic recommendation"
],
"need_citation_expansion": true,
"reason": "当前候选集中已有 PaSa/SPAR 类论文，但缺少引文追踪和 benchmark evaluation 方向论文。"
}

```

作用

这一阶段直接对应赛题要求：

搜索结果过滤不相干、低质量论文。

支持迭代式检索策略：根据已找到的相关论文信息，动态调整检索策略和关键词。

3.5 Search Strategy Optimization Agent：搜索策略优化 Agent

任务

根据 Result Review Agent 的审阅结果，生成下一轮检索计划。

决策类型

判断结果	下一步动作
主题覆盖不足	增加 topic route


判断结果	下一步动作
方法约束缺失	增加 method route
数据集约束缺失	增加 dataset route
年份不够新	增加 latest route
缺少经典论文	开启 reference expansion
缺少后续工作	开启 citation expansion
噪声过多	增加 negative keywords
候选足够	停止检索，进入筛选
预算不足	停止检索，进入降级排序

示例第二轮搜索策略

```
{
  "round": 2,
  "search_goal": "补充引文追踪和 benchmark evaluation 方向论文",
  "new_subqueries": [
    {
      "query": "scholarly paper retrieval benchmark reranking citation",
      "reason": "补充 benchmark 和 reranking 方向"
    },
    {
      "query": "citation-aware academic paper recommendation LLM",
      "reason": "补充引文感知推荐方向"
    },
    {
      "query": "PaperFindingBench academic search agent",
      "reason": "根据候选论文中出现的新 benchmark 扩展"
    }
  ],
  "citation_expansion_seeds": [
    "PaSa",
    "SPAR",
    "Ai2 Paper Finder"
  ],
  "negative_filters": [
    "general web search",
    "chatbot only",
    "non-scholarly recommendation"
  ],
  "stop_after_this_round": false
}
```

四、迭代搜索循环设计

4.1 标准迭代流程



4.2 最大迭代次数

建议设置:

```
max_agent_rounds: 3
max_subqueries_per_round: 5
max_candidates_per_round: 100
max_total_candidates: 500
max_citation_expansion_seeds: 10
max_citation_expansion_per_seed: 5
```

4.3 停止条件

满足以下任一条件即可停止:

1. 高置信候选论文数量达到要求;
2. hard constraints 覆盖率达到阈值;
3. 连续两轮新增高质量论文很少;
4. 候选池已覆盖主要子问题;
5. API 或 Token 预算接近上限;

6. LLM 判断继续搜索收益有限；
7. 达到最大迭代轮数。

4.4 LLM 停止判断输出

```
{
  "should_stop": true,
  "reason": "当前候选池已覆盖查询中的 LLM agent、academic paper search、query decomposition、reranking、citation expansion 等主要约束，继续搜索预计收益有限。",
  "remaining_risks": [
    "可能仍缺少部分最新 2026 论文",
    "部分论文摘要中未明确说明 benchmark"
  ],
  "next_stage": "evidence_filtering_and_reranking"
}
```

五、最终排序阶段调整

原来的排序阶段是：

BGE-reranker-v2 对 top300 排序，可选 LLM 对 top20 二次判断。

调整后应改为：

LLM Evidence Selector + BGE-reranker + Evidence Validator + 综合排序公式

5.1 Evidence Selector Agent

任务

对候选论文进行细粒度相关性判断，区分高度相关、部分相关、低相关、不相关。

输入

```
用户原始 query
Query Contract
候选论文 title
候选论文 abstract
year
venue
citation count
retrieval path
```

输出

```
{
  "paper_id": "xxx",
  "relevance_level": "high",
  "matched_constraints": [
    "academic paper search",
    "LLM agent",
    "query decomposition"
  ],
  "missing_constraints": [
    "citation expansion not explicit"
  ],
  "evidence": [
    {
      "field": "abstract",
      "text": "..."
    }
  ],
  "reason": "该论文直接提出面向学术论文搜索的 LLM Agent，并包含查询分解和候选筛选机制。",
  "confidence": 0.88
}
```

5.2 Evidence Validator

LLM 给出的证据必须做本地校验。

如果 LLM 说论文使用了某数据集，但 title/abstract/metadata 中找不到，则降级。

如果 LLM 说论文属于 2024 年以后，但 metadata 年份不符，则降级。

如果 LLM 说 highly relevant，但缺少核心硬约束证据，则降级为 partially relevant。

5.3 最终排序公式

```
FinalScore =
0.25 * LLM_RelevanceScore
+ 0.20 * BGE_RerankerScore
+ 0.20 * ConstraintCoverage
+ 0.15 * EvidenceCompleteness
+ 0.10 * SourceAgreement
+ 0.05 * Recency
+ 0.03 * Authority
+ 0.02 * DiversityGraphPrior
```

说明

- LLM_RelevanceScore 体现 Agent 判断。

- BGE_RerankerScore 保证语义精排稳定。
- ConstraintCoverage 保证复杂查询硬条件优先。
- EvidenceCompleteness 防止无证据高排名。
- SourceAgreement 奖励多源、多轮、多 route 同时召回的论文。
- DiversityGraphPrior 只做轻量辅助，防止结果过于集中。

六、结构化输出阶段调整

最终输出不应只是论文列表，而应体现 Agent 的搜索过程、审阅过程和归纳能力。

6.1 输出结构

```
{
  "query_understanding": {},
  "search_process": [],
  "highly_relevant_papers": [],
  "partially_relevant_papers": [],
  "method_clusters": [],
  "timeline": [],
  "citation_graph": {},
  "recommendation_reasoning": [],
  "agent_self_report": {},
  "run_metrics": {}
}
```

6.2 高度相关论文

高度相关论文必须满足：

1. 主题匹配；
2. 核心方法匹配；
3. 关键约束匹配；
4. 有 title/abstract/metadata 证据；
5. LLM 和 reranker 判断一致或基本一致。

6.3 部分相关论文

部分相关论文包括：

1. 主题相关但缺少某个硬约束；
2. 方法相关但场景不同；
3. 是经典背景论文；
4. 是某个子方向的代表工作；
5. 证据不足但值得用户进一步查看。

6.4 Agent 搜索过程报告

为了体现“自主搜索策略迭代优化”，最终结果中建议展示：

第 1 轮搜索：

- 搜索目标：覆盖主题和核心方法
- 使用关键词：...
- 找到候选：...
- LLM 审阅结论：缺少某某方向

第 2 轮搜索：


- 搜索目标：补充 benchmark 和 citation-aware reranking
- 新增关键词：...
- 引文扩展 seed：...
- 找到新增高质量论文：...

停止原因：

- 主要约束已覆盖
- 新增高质量论文减少
- 进入最终证据筛选

这部分非常重要，因为它直接展示赛题第二条要求。

七、调整后的最终 workflows



[Tools] 二轮检索 + 引文扩展 + 相似论文扩展



Candidate Pool Round 2



[LLM Agent 3] Result Review



Stop or Continue



Final Candidate Pool



[LLM Agent 5] Evidence Selector



Evidence Validator



BGE-reranker / Cross-Encoder



Final Reasoning Reranker



[LLM Agent 6] Structured Synthesis



高度相关论文

部分相关论文

方法分类

时间线

引用关系图

推荐理由

Agent 搜索过程报告

RunMetrics

八、与赛题要求的逐条对应

赛题要求	调整后对应模块
解析用户自然语言查询中的核心研究意图	Query Understanding Agent
识别关键实体、方法论约束、数据/领域限定	Query Contract
复杂查询拆解为子问题	Search Planning Agent
查询改写与扩展	Query Planner + Strategy Optimization Agent
自主规划搜索词进行搜索	LLM Search Planning Agent
过滤不相干、低质量论文	Result Review Agent + Evidence Selector
根据已找到论文动态调整策略和关键词	Result Review Agent + Strategy Optimization Agent
基于标题、摘要、可用全文进行细粒度相关性评估	Evidence Selector + Evidence Validator
输出排序后的最终论文列表	Final Reranker

赛题要求	调整后对应模块
区分高度相关和部分相关	Evidence-based relevance classification
根据用户查询意图归纳结果	Structured Synthesis Agent
返回列表、关系图等结构化展示	Evidence Card + Citation Graph + Research Map
成本控制	BudgetManager + RunMetrics

九、成本控制如何体现

虽然 LLM API 充足，但赛题仍然会考虑 API 调用次数和 Token 消耗，因此不能无限调用。

9.1 成本控制原则

1. LLM 负责策略，不负责全量候选逐篇阅读。
2. 每轮只让 LLM 审阅 top 30-50 候选摘要。
3. 每个 query 最多 2-3 轮迭代。
4. 引文扩展只对高置信 seed 开启。
5. LLM 二次精排只处理 top 20。
6. 所有 LLM 输出必须缓存。
7. 最终展示 RunMetrics。

9.2 RunMetrics

```
{
  "agent_rounds": 2,
  "search_queries_generated": 9,
  "api_calls": {
    "openalex": 5,
    "semantic_scholar": 4,
    "arxiv": 2
  },
  "llm_calls": {
    "query_understanding": 1,
    "search_planning": 1,
    "result_review": 2,
    "strategy_optimization": 1,
    "evidence_selection": 3,
    "structured_synthesis": 1
  },
  "token_usage_estimate": 18500,
  "elapsed_seconds": 42.6,
  "cache_hits": 7,
  "stop_reason": "coverage_sufficient"
}
```

这既能满足成本控制要求，也能在答辩中说明系统不是黑盒 Agent。

十、最终推荐的实现优先级

P0：必须实现

Query Understanding Agent
Search Planning Agent
多源检索工具
Result Review Agent
Strategy Optimization Agent
最多 2 轮迭代检索
Evidence Selector
Evidence Validator
Final Reranker
RunMetrics
结构化输出

P1：强烈建议实现

BGE-M3
BGE-reranker-v2
SPECTER2
一跳 RefChain
Citation Graph
Evidence Card
Agent 搜索过程报告

P2：有余力实现

LLM top20 listwise rerank
全文片段证据增强
Query robustness test
Graph-based diversity control
多领域 benchmark

十一、最终结论

调整后的系统不再是单纯的“检索流水线”，而是一个真正符合赛题要求的 **LLM-driven Scholarly Search Agent**。

其核心特征是：

1. **LLM 主动规划搜索策略；**
2. **LLM 审阅检索结果并发现缺口；**

3. LLM 根据已有论文动态生成下一轮关键词；
4. 工具层执行多源检索、语义检索和引用扩展；
5. LLM 参与证据约束的相关性筛选；
6. 系统保留预算控制、停止条件和成本日志；
7. 最终输出论文列表、关系图、推荐理由和 Agent 搜索过程报告。

最终一句话表述为：

本系统构建了一个预算受控的学术论文搜索 Agent。它能够理解复杂科研查询，自主规划并迭代优化搜索策略，根据已检索到的论文动态调整关键词和引用扩展方向，最终通过证据约束排序和结构化归纳，输出高度相关与部分相关论文集合及其推荐依据。